

异步多 Agent 的奖励校准同伴学习

组织架构与算法核心

Idea note | 2026 年 10 月 2 日

核心理念

多个同构 Agent 从同一初始大模型出发，在各自环境中解题并独立进行 GRPO 更新。每次更新完成后，Agent 异步广播模型快照；接收者把本轮缓存中的同伴模型锁定为伪教师，在自己的轨迹上获得 token 级概率差。终局正确性与教师对实际答案的偏好共同决定保留或反转这一辅助信号。核心是把独立解题、异步模型交流和奖励校准的 top-4 同伴 OPD 连接成持续学习循环，目标是改善群体的平均解题能力。

1 组织架构与策略角色

系统包含一个同类问题库、外部强模型裁判以及 N 个独立 Agent。问题库提供题目，裁判提供终局正确性标签；每个 Agent 持有自己的解题环境、本地轨迹、可训练参数和接收缓存。所有 Agent 的有效策略从相同参数开始：

$$\theta_a^{(0)} = \theta_0, \quad a \in \{1, \dots, N\}. \quad (1)$$




图 1: 逻辑组织结构。问题库、裁判和广播通道表示共享接口；各 Agent 的解题、缓存和优化过程独立。

一轮内区分三个版本： π_{old} 是生成本轮轨迹的固定行为策略； π_T 是本轮锁定的同伴伪教师； π_θ 是当前被优化的本地策略。广播快照提供训练信号，不覆盖本地模型。本地梯度只更新接收者自己的可训练参数，可对应冻结基座上的 LoRA 适配器。

2 异步协调与缓存协议

2.1 本轮接收窗口与教师锁定

轮次 b 由 Agent a 自己推进，没有统一的全局训练轮次。每轮开始接题时先清空缓存，删除上轮所有遗留快照。令 $t_{a,b}^{\text{start}}$ 为本轮开始时刻， $t_{a,b}^A$ 为整批奖励与 GRPO 优势计算完成时刻， $t_{a,e}^{\text{arr}}$ 为条目 e 在接收者处的到达时刻。条目携带发送者身份、发送者本地更新编号、快照身份和接收时间。本轮可用集合为：

$$\mathcal{C}_{a,b} = \left\{ e : t_{a,b}^{\text{start}} \leq t_{a,e}^{\text{arr}} \leq t_{a,b}^A \right\}. \quad (2)$$

若集合为空，本轮使用本地 GRPO 与参考 KL，不使用同伴 OPD。若非空，按接收者的到达时间选最新快照；最新到达时间并列时，仅在并列集合中均匀随机选择一个：

$$\begin{aligned} t_{a,b}^{\max} &= \max_{e \in \mathcal{C}_{a,b}} t_{a,e}^{\text{arr}}, \\ \mathcal{E}_{a,b} &= \left\{ e \in \mathcal{C}_{a,b} : t_{a,e}^{\text{arr}} = t_{a,b}^{\max} \right\}, \\ e_{a,b}^* &\sim \text{Unif}(\mathcal{E}_{a,b}), \quad \pi_{a,b}^T = \pi_{e_{a,b}^*}^{\text{snapshot}}. \end{aligned} \quad (3)$$

到达时间恰好等于优势完成时间的广播纳入选择。教师选定后锁定至本轮优化结束。之后到达的快照继续进入缓存，但不触发换教师、重算评分或改变本轮分支；下一轮开始时删除。不同 Agent 的本地更新编号不用于比较全局新旧，最新到达也不代表性能最好。

2.2 各 Agent 如何并行推进

每个 Agent 执行“接题与 rollout $\rightarrow$ 判题与优势 $\rightarrow$ 教师选择与评分 $\rightarrow$ 本地优化 $\rightarrow$ 广播”的循环。有教师时，全部 128 条轨迹在优势完成前已生成，因此本轮最终教师的评分顺序为：

$$t_{a,b}^{\text{roll}} \leq t_{a,b}^A = t_{a,b}^{\text{select}} \leq t_{a,b}^{T,\text{start}} \leq t_{a,b}^T \leq t_{a,b}^{\text{opt,start}}. \quad (4)$$

式中， a 是 Agent 编号， b 是该 Agent 的本地批次编号；各时间点均指同一 Agent 的同一批次：

时间变量	含义
$t_{a,b}^{\text{roll}}$	本批全部 128 条 rollout 完成的时刻
$t_{a,b}^A$	本批全部终局奖励与 GRPO 优势计算完成的时刻
$t_{a,b}^{\text{select}}$	从本轮缓存中选择并锁定伪教师的逻辑时刻
$t_{a,b}^{T,\text{start}}$	锁定教师开始对本批轨迹评分的时刻
$t_{a,b}^T$	锁定教师完成本批全部所需评分的时刻
$t_{a,b}^{\text{opt,start}}$	本地模型开始本批参数优化的时刻

等号 $t_{a,b}^A = t_{a,b}^{\text{select}}$ 表示在优势完成事件上选择教师；无教师时跳过教师评分阶段。

教师对整批评分完毕后，本地 Agent 才开始联合更新；无需等待其他 Agent 完成本轮。同一 Agent 更新期间停止接新题，其余 Agent 仍可解题、评分或更新。若全部 Agent 都处于更新阶段，系统暂时停止接新题。每次本地更新结束，立即把不可变的新快照广播到其余所有 Agent 的缓存，包括联合更新与停止阶段的更新；随后按照接题状态进入下一轮。停止阶段完成已经开始的 rollout、评分和更新。异步重叠发生在不同 Agent 之间，本轮最终教师评分不与本轮尚未完成的 rollout 重叠。

3 本地轨迹、终局奖励与 GRPO 优势

Agent 每轮从题库抽取 16 道题，每题生成 8 条本地轨迹。题目索引 q 、同题轨迹索引 k 与批次轨迹编号 i 的对应关系为：

$$Q = 16, \quad G = 8, \quad B = QG = 128, \quad i = (q - 1)G + k. \quad (5)$$

轨迹 τ_i 可以包含多轮读代码、修改代码、运行测试和后续修复。 y_{it} 是本地策略生成的 token， h_{it} 是其生成前的真实上下文，包含题目、之前的动作和环境反馈。整批 rollout 使用同一个 π_{old} ，广播不会改变该行为策略。教师始终在同一 h_{it} 上评分，不重新运行自己的环境路径。

令 z_i 为最终答案， $\mathcal{V}(x_q, z_i)$ 为外部强模型裁判的正确性标签，正确为 1、错误为 0。终局奖励为：

$$R_i = \begin{cases} +1, & \mathcal{V}(x_q, z_i) = 1, \\ -1, & \mathcal{V}(x_q, z_i) = 0. \end{cases} \quad (6)$$

GRPO 在同一道题的 8 条轨迹内部进行相对比较，不把不同题目的奖励合成一个组。奖励均值与样本标准差为：

$$\bar{R}_q = \frac{1}{G} \sum_{k=1}^G R_{q,k}, \quad s_q = \sqrt{\frac{1}{G-1} \sum_{k=1}^G (R_{q,k} - \bar{R}_q)^2}. \quad (7)$$

样本标准差的分子是 $G - 1 = 7$ 。仅当标准差为零时，将优势归一化分母替换为正小量 ϵ_{std} ；轨迹级优势复制到参与 GRPO 的本地动作 token：

$$\tilde{\sigma}_q = \begin{cases} s_q, & s_q > 0, \\ \epsilon_{\text{std}}, & s_q = 0, \end{cases} \quad A_{q,k,t}^G = A_{q,k}^G = \frac{R_{q,k} - \bar{R}_q}{\tilde{\sigma}_q}, \quad \epsilon_{\text{std}} > 0. \quad (8)$$

若 8 条轨迹全对或全错，分子也为零，故 GRPO 优势为零。该组仍留在批次中；同伴 OPD 与参考 KL 按各自规则计算。 F_i 表示最终答案的实际 token 位置， M_i^G 、 M_i^D 、 M_i^K 分别表示三类损失的本地动作掩码。它们作为输入接口贯穿后续公式；环境观察可进入上下文，但不动作为被优化的动作 token。

4 用终局正确性校准同伴信号方向

选定伪教师后，接收者在自己的实际最终答案上做 teacher-forcing 评分。对于非空 F_i ，分别计算教师与本地旧模型的答案平均 token 对数概率：

$$\bar{\ell}_i^T = \frac{1}{|F_i|} \sum_{t \in F_i} \log \pi_T(y_{it} | h_{it}), \quad \bar{\ell}_i^{\text{old}} = \frac{1}{|F_i|} \sum_{t \in F_i} \log \pi_{\text{old}}(y_{it} | h_{it}). \quad (9)$$

$$J_i = \bar{\ell}_i^T - \bar{\ell}_i^{\text{old}} = \frac{1}{|F_i|} \sum_{t \in F_i} \log \frac{\pi_T(y_{it} | h_{it})}{\pi_{\text{old}}(y_{it} | h_{it})}, \quad |F_i| > 0. \quad (10)$$

$J_i > 0$ 表示教师更支持这段实际答案， $J_i < 0$ 表示支持程度更低。结合裁判提供的终局奖励，定义保留、反转或关闭同伴信号的轨迹级符号：

$$\lambda_i = \begin{cases} 0, & |F_i| = 0, \\ +1, & |F_i| > 0 \wedge (R_i J_i > 0 \vee J_i = 0), \\ -1, & |F_i| > 0 \wedge R_i J_i < 0. \end{cases} \quad (11)$$

终局奖励	J_i	λ_i	同伴信号方向
+1	> 0	+1	保留：教师支持正确答案
+1	< 0	-1	反转：教师压低正确答案
-1	< 0	+1	保留：教师压低错误答案
-1	> 0	-1	反转：教师支持错误答案

非空答案的 $J_i = 0$ 时取 $\lambda_i = +1$ ，保留普通同伴信号；平均差值为零并不意味着每个 token 的差值为零。最终答案为空时，先直接取 $\lambda_i = 0$ ，不计算 J_i ，并把该轨迹的 OPD 损失显式置零；原 GRPO 分组与优势保持不变。

这一校准对整条轨迹提供方向，而不是逐步正确性标签。 J_i 比较的是同一段本地答案的概率，不是教师自身的解题成功率。反向蒸馏意味着反转接收者的 OPD 优势，不是训练教师，也不是交换 KL 的方向。

5 固定旧模型 top-4 的 token 级同伴优势

对每个本地轨迹前缀 h_{it} ，仅取本轮行为策略的 top-4 词表 token 作为候选集合。在整轮评分与优化期间，候选身份固定：

$$S_{it} = \text{Top4}(\pi_{\text{old}}(\cdot | h_{it})), \quad |S_{it}| = 4. \quad (12)$$

top-4 表示在相同前缀上评分 4 个候选 token，不生成额外完整轨迹。伪教师对这些候选评分，当前本地模型在优化时重算它们的概率。对 $v \in S_{it}$ ，三组对数概率为：

$$\ell_{itv}^{\text{old}} = \log \pi_{\text{old}}(v | h_{it}), \quad \ell_{itv}^T = \log \pi_T(v | h_{it}), \quad \ell_{itv}^\theta = \log \pi_\theta(v | h_{it}). \quad (13)$$

上述概率来自完整词表 softmax。只有用于候选加权的 w_{itv} 在 top-4 内归一化；师生差值与新旧策略比率仍使用完整词表概率：

$$w_{itv} = \frac{\exp(\ell_{itv}^{\text{old}})}{\sum_{u \in S_{it}} \exp(\ell_{itu}^{\text{old}})}, \quad \sum_{v \in S_{it}} w_{itv} = 1. \quad (14)$$

教师与本地旧模型的 logprob 差值先做对称幅度裁剪，再乘轨迹级校准符号与候选权重：

$$d_{itv} = \ell_{itv}^T - \ell_{itv}^{\text{old}}, \quad \Delta_{itv} = \text{clip}(d_{itv}, -C, C), \quad C > 0. \quad (15)$$

$$\boxed{a_{itv}^{\text{peer}} = \text{sg}[\lambda_i w_{itv} \Delta_{itv}]}, \quad \lambda_i \in \{-1, +1\}. \quad (16)$$

sg 表示 stop-gradient。旧模型、教师、候选身份、权重、差值与 λ_i 均为固定训练信号。 $\lambda_i = +1$ 保留该信号， -1 反转其方向，0 的轨迹直接走零损失分支。梯度只经当前策略的概率流向本地可训练参数。

评分数据需同时包含实际答案 token 和 top-4 候选的 logprob：实际生成 token 可能不在 top-4 内，但计算 J_i 仍需要它。对候选求和时不再除以 4，因为 w_{itv} 已归一化。

6 分别裁剪的双分支目标与本地更新

OPD 对候选 token、GRPO 对实际采样 token 分别计算新旧本地策略概率比率。教师不位于任何比率的分母：

$$\rho_{itv}(\theta) = \frac{\pi_{\theta}(v \mid h_{it})}{\pi_{\text{old}}(v \mid h_{it})}, \quad r_{it}(\theta) = \frac{\pi_{\theta}(y_{it} \mid h_{it})}{\pi_{\text{old}}(y_{it} \mid h_{it})}. \quad (17)$$

$$c_X(r) = \text{clip}\left(r, 1 - \epsilon_X^{\text{low}}, 1 + \epsilon_X^{\text{high}}\right), \quad X \in \{\text{G}, \text{D}\}. \quad (18)$$

两条分支的 PPO clipped-surrogate 损失分别为：

$$L_{it}^{\text{G}} = -\min\left\{r_{it}A_i^{\text{G}}, c_{\text{G}}(r_{it})A_i^{\text{G}}\right\}. \quad (19)$$

$$U_{it}^{\text{peer}} = -\sum_{v \in S_{it}} \min\left\{\rho_{itv}a_{itv}^{\text{peer}}, c_{\text{D}}(\rho_{itv})a_{itv}^{\text{peer}}\right\},$$

$$L_{it}^{\text{peer}} = \begin{cases} 0, & \lambda_i = 0, \\ U_{it}^{\text{peer}}, & \lambda_i \in \{-1, +1\}. \end{cases} \quad (20)$$

对各分支，先按各自动作掩码在每条轨迹内求 token 损失均值，再对本批 $B = 128$ 条轨迹等权平均，随后组合：

$$\mathcal{R}_M(X) = \frac{1}{B} \sum_{i=1}^B \left(\frac{1}{|M_i|} \sum_{t \in M_i} X_{it} \right), \quad |M_i| > 0 \quad (i = 1, \dots, B). \quad (21)$$

$$\boxed{\mathcal{L}_{\text{total}} = \alpha \mathcal{R}_{M^{\text{G}}}(L^{\text{G}}) + \beta \mathcal{R}_{M^{\text{D}}}(L^{\text{peer}}) + 0.01 \mathcal{L}_{\text{KL}}}. \quad (22)$$

α, β 分别控制 GRPO 与同伴 OPD 的贡献。每条轨迹在批次平均中权重相同，轨迹长度不再直接决定其批次权重。空答案的零 OPD 轨迹项仍计入分母 B ，不只对非零 λ_i 的轨迹重新归一化。GRPO、同伴 OPD 与参考 KL 均使用此汇总规则。没有合格教师时执行本地 GRPO 与参考 KL。 $\mathcal{L}_{\text{KL}}$ 是独立的参考策略正则项，系数为 0.01，不乘 λ_i 。

先反转优势，再进入 min/clip，不能先算普通 OPD 损失后整体乘负号。因为：

$$\begin{aligned} \ell(r, -a) &= \max\{ra, c(r)a\}, \\ -\ell(r, a) &= \min\{ra, c(r)a\}, \quad \ell(r, a) = -\min\{ra, c(r)a\}. \end{aligned} \quad (23)$$

同理，先分别裁剪再组合，不把两种优势先相加后只裁剪一次。这里使用 PPO 裁剪形式，并未增加独立 PPO critic 或额外历史轨迹更新。

7 端到端循环与方法定位

7.1 每个 Agent 的独立事件循环

1. 开始一轮：清空旧缓存，固定本轮 π_{old} ，抽取 16 道题并各采样 8 条轨迹；收到同伴广播时写入本轮缓存。
2. 裁判返回终局奖励；在同题 8 条轨迹内计算均值、样本标准差与 A_t^G 。
3. 优势完成时读取缓存，纳入同时到达条目；无教师则进入本地更新，否则选最新到达教师，并列均匀抽样后锁定。
4. 有教师时，对整批本地前缀评分；计算实际答案的 J_i, λ_i 与固定旧模型 top-4 上的 $w_{itv}, \Delta_{itv}, a_{itv}^{\text{peer}}$ 。
5. 本地优化当前策略：分别裁剪 GRPO 和 OPD 分支，先在轨迹内平均 token 损失，再对批次轨迹等权平均并组合，加入参考 KL；旧模型与教师不更新。
6. 更新完成立即广播新快照，依据接题状态开始下一轮；停止阶段完成在途工作，完成的更新同样广播。

7.2 参考 KL 的接口

参考策略 π_{ref} 与同伴教师具有不同角色，只提供参考评分。k3 / low-var 参考 KL 的共享核心及其批次汇总可写为：

$$\begin{aligned}\delta_{it}(\theta) &= \log \pi_{\text{ref}}(y_{it} \mid h_{it}) - \log \pi_{\theta}(y_{it} \mid h_{it}), \\ K_{it}^{(3)}(\theta) &= \exp(\delta_{it}(\theta)) - 1 - \delta_{it}(\theta), \\ \mathcal{L}_{\text{KL}} &= \mathcal{R}_{M^{\text{K}}} \left(g_{\text{KL}} \left(K_{it}^{(3)}(\theta) \right) \right).\end{aligned}\tag{24}$$

g_{KL} 封装所采用的参考 KL 数值实现，参考策略、动作掩码和训练超参数作为算法输入；本 idea 不展开这些配置。该项的梯度流向当前本地策略，不对它整体 stop-gradient，也不因空最终答案自动关闭。

7.3 核心研究命题

本方法借鉴 GRPO、PPO 裁剪和 OpenClaw-RL 的 top-k OPD 结构。其研究焦点是：异步独立学习者能否通过同伴快照，在自己的轨迹上构造经终局奖励校准的辅助优势。这里广播的是模型知识，实际训练数据仍来自接收者自己的策略。 λ_i 是整段方向校准，不能保证每个局部步骤正确，也不能保证成功率单调提升。本文提出机制与假设，不给出实验结论。