

异步多 Agent 的 GRPO + OPD

四种训练设定与完整流程

方法记录 | 2026 年 10 月 3 日

内容概述

本记录统一说明 Terminal 与 Tool-call 两种轨迹组织方式，以及 PRM 关闭与开启两种奖励设定。四种设定共享独立 rollout、异步快照广播、接收者本地训练和终局奖励校准的 top-4 同伴 OPD。已确认的基线不开 PRM；PRM 开启版本记录结构性扩展，未确认的权重和边界处理保持显式接口。本记录不包含实验结论或参考文献。

1 四种设定与基本符号

设定	PRM	轨迹存储	GRPO 优势
Terminal	关闭	每步一份样本	整条轨迹共用 A_i^G
Terminal	开启	每步一份样本	第 t 步使用 $A_{i,t}^G$
Tool-call	关闭	整条轨迹一份长样本	所有动作 token 共用 A_i^G
Tool-call	开启	长样本附带步骤范围	按范围赋予 $A_{i,t}^G$

一轮含 16 道题、每题 8 条完整轨迹。 q 是批内题目编号， j 是问题候选轨迹编号， i 是完整轨迹编号； t 是环境交互步骤， k 是本步输出的 token 位置， T_i 是轨迹步数。

$$Q = 16, \quad G = 8, \quad B = QG = 128, \quad i = (q - 1)G + j. \quad (1)$$

一次动作 $a_{i,t}$ 包含模型实际输出的思考文本、工具调用或最终回答。动作执行后返回观察 $o_{i,t}$ ；第 t 步输入 $s_{i,t}$ 使用此前已经获得的观察与保留历史：

$$\begin{aligned} s_{i,t} &= \text{Format}(\text{system}, x_q, o_{i,0}, a_{i,1}, o_{i,1}, \dots, a_{i,t-1}, o_{i,t-1}), \\ h_{i,t,k} &= (s_{i,t}, y_{i,t,<k}), \quad a_{i,t} = (y_{i,t,1}, \dots, y_{i,t,L_{i,t}}). \end{aligned} \quad (2)$$

$s_{i,t}$ 是实际格式化输入，不是环境全部真实状态。 $h_{i,t,k}$ 是生成本 token 前的上下文；历史保留和截断由实际输入接口决定。PRM 关闭时，工具观察不会自动转成独立过程奖励。

2 共同组织架构与独立学习循环

系统由同类题库、外部强模型裁判以及 N 个独立 Agent 构成。每个 Agent 持有自己的环境实例、轨迹、可训练参数和接收缓存，初始有效策略相同：

$$\theta_a^{(0)} = \theta_0, \quad a \in \{1, \dots, N\}. \quad (3)$$




图 1: 共享接口与独立学习者。PRM 是可选的步骤评分接口，不改变同伴快照的角色。

2.1 四类策略的角色

- π_{old} : 固定的本轮本地行为策略，生成全部 128 条轨迹并提供概率比的分母。
- π_{θ} : 从本地旧模型开始优化的当前策略；只有本地已指定的可训练参数接收梯度。
- π_T : 从本轮缓存选出的冻结同伴伪教师，仅在接收者自己的前缀上评分。
- π_{ref} : 参考 KL 的评分策略，其角色与伪教师不同。

所有轨迹保持本地 on-policy 采样：接收广播不替换正在采样的旧模型，也不引入其他 Agent 的轨迹。每次本地更新完成后广播新快照，包括 GRPO + OPD 的联合更新结果。各 Agent 无需等待其他 Agent 完成同一轮。

3 缓存、教师锁定与异步时序

3.1 本轮缓存的有效窗口

a 是 Agent 编号, b 是其本地批次编号。每轮开始接题时清空整个缓存, 删除上轮遗留快照, 包括上轮评分或更新期间收到的模型。令 $t_{a,b}^{\text{start}}$ 为本轮开始时刻, $t_{a,e}^{\text{arr}}$ 为快照 e 的接收时间:

$$\mathcal{C}_{a,b} = \{e : t_{a,b}^{\text{start}} \leq t_{a,e}^{\text{arr}} \leq t_{a,b}^{\text{A}}\}. \quad (4)$$

$t_{a,b}^{\text{A}}$ 是整批所需奖励与 GRPO 优势完成时刻。PRM 开启时, 它还要求本批所需的过程评分已经就绪。条目记录发送者、发送者本地更新编号、不可变快照身份和接收时间。缓存为空时, 本轮使用本地 GRPO 与参考 KL。否则在优势完成事件上选择最新到达的快照; 并列时只从最新并列集合中均匀随机选一个:

$$\begin{aligned} u_{a,b} &= \max_{e \in \mathcal{C}_{a,b}} t_{a,e}^{\text{arr}}, \\ \mathcal{E}_{a,b} &= \{e \in \mathcal{C}_{a,b} : t_{a,e}^{\text{arr}} = u_{a,b}\}, \\ e_{a,b}^* &\sim \text{Unif}(\mathcal{E}_{a,b}), \quad \pi_T = \pi_{e_{a,b}^*}^{\text{snapshot}}. \end{aligned} \quad (5)$$

恰好在优势完成时到达的条目可用。选定教师锁定至本轮优化结束; 后续广播继续入缓存, 但不改教师、不重评分、不改本轮分支, 下一轮开始时删除。最新到达不代表性能最好, 发送者本地更新号不能当作全局版本。

3.2 时间变量与协调规则

$$t_{a,b}^{\text{roll}} \leq t_{a,b}^{\text{A}} = t_{a,b}^{\text{select}} \leq t_{a,b}^{\text{T,start}} \leq t_{a,b}^{\text{T}} \leq t_{a,b}^{\text{opt,start}}. \quad (6)$$

时间变量	同一 Agent、同一批次中的事件
$t_{a,b}^{\text{roll}}$	全部 128 条完整 rollout 结束
$t_{a,b}^{\text{A}}$	所需奖励与 GRPO 优势全部完成
$t_{a,b}^{\text{select}}$	逻辑上的教师选择与锁定
$t_{a,b}^{\text{T,start}}$	锁定教师开始评分本批轨迹
$t_{a,b}^{\text{T}}$	所需教师评分全部完成
$t_{a,b}^{\text{opt,start}}$	本地参数优化开始

无教师时跳过教师评分阶段。PRM 可在交互期间评分, 但最终选定的同伴教师只能在优势完成后开始本批评分。异步重叠发生在不同 Agent 之间。更新期间本地暂停接题; 其余 Agent 正常推进, 全部更新时暂时无新题接入。停止阶段完成已开始的 rollout、评分和更新, 并广播完成的更新。

4 PRM 关闭：轨迹级 GRPO 优势

4.1 终局奖励与同题分组

z_i 是最终答案， $\mathcal{V}(x_q, z_i)$ 是外部强模型裁判返回的正确性标签。可判定的终局答案按已确认规则给奖励：

$$O_i = \begin{cases} +1, & \mathcal{V}(x_q, z_i) = 1, \\ -1, & \mathcal{V}(x_q, z_i) = 0. \end{cases} \quad (7)$$

中间工具执行结果、报错或测试输出进入后续上下文，但不自动映射为独立的正负过程分数。终局奖励缺失时不能擅自给 -1 ；该失败处理仍是未确定的输入接口。GRPO 的 group 是同一道初始题目的 8 条完整轨迹，完整轨迹的奖励只统计一次：

$$\mu_q = \frac{1}{8} \sum_{j=1}^8 O_{q,j}, \quad \sigma_q = \sqrt{\frac{1}{7} \sum_{j=1}^8 (O_{q,j} - \mu_q)^2}. \quad (8)$$

样本标准差分母为 7，仅在标准差等于零时替换为正小量：

$$\tilde{\sigma}_q = \begin{cases} \sigma_q, & \sigma_q > 0, \\ \epsilon_{\text{std}}, & \sigma_q = 0, \end{cases} \quad A_{q,j}^G = \frac{O_{q,j} - \mu_q}{\tilde{\sigma}_q}, \quad \epsilon_{\text{std}} > 0. \quad (9)$$

4.2 优势广播与训练时机

令 $M_{i,t}^X$ 为分支 X 在第 t 步使用的有效输出 token 位置， X 可为 GRPO、同伴 OPD 或参考 KL。GRPO 优势原样复制到轨迹的各步输出：

$$\boxed{A_{i,t,k}^G = A_i^G}, \quad k \in M_{i,t}^G. \quad (10)$$

这里不除以步数或本步 token 数。每个 token 的概率比不同，因此相同优势仍可产生不同损失。整批样本汇总后进行本地更新，不是在每次环境转移后独立运行一次 GRPO。例如某条 3 步轨迹得到 $A_i^G = 0.8$ ，它三个步骤的有效输出 token 均使用 0.8，包括早期失败的尝试。该信号反映完整轨迹的相对结果，不证明每个动作都正确。若同题 8 条轨迹全部成功或全部失败，分子和标准差都为零，所得 GRPO 优势为零。该组仍保留；同伴 OPD 和参考 KL 可以继续作用。无 PRM 时，这一规则对 Terminal 和 Tool-call 完全相同。

5 PRM 开启：步骤级 GRPO 优势

5.1 先合成奖励，再按步骤标准化

$P_{i,t}$ 是 PRM 对当前步骤“思考 + 操作是否推进解题”的评分。题目、实际历史、当前动作和动作后的观察可以作为其判断依据；报错不必然表示动作无效。本记录用符号 η 表示未确认的过程奖励权重：

$$R_{i,t} = O_i + \eta P_{i,t}. \quad (11)$$

同一终局奖励 O_i 加到该轨迹每一步，过程评分随步骤变化。先合成 $R_{i,t}$ ，再做组内相对比较，不分别标准化终局奖励与 PRM 分数后相加。比较组由“同一道题、相同交互步骤编号”确定。不同轨迹长度可以不同，定义实际包含该步骤的候选集合：

$$\mathcal{I}_{q,t} = \{j \in \{1, \dots, 8\} : T_{q,j} \geq t\}, \quad n_{q,t} = |\mathcal{I}_{q,t}|. \quad (12)$$

先说明 8 条候选都包含该步、奖励均已有效取得时的计算，沿用样本标准差约定：

$$\mu_{q,t} = \frac{1}{8} \sum_{j=1}^8 R_{q,j,t}, \quad \sigma_{q,t} = \sqrt{\frac{1}{7} \sum_{j=1}^8 (R_{q,j,t} - \mu_{q,t})^2}, \quad n_{q,t} = 8. \quad (13)$$

$$\tilde{\sigma}_{q,t} = \begin{cases} \sigma_{q,t}, & \sigma_{q,t} > 0, \\ \epsilon_{\text{std}}, & \sigma_{q,t} = 0, \end{cases} \quad (14)$$

$$\boxed{A_{q,j,t,k}^G = A_{q,j,t}^G} = \frac{R_{q,j,t} - \mu_{q,t}}{\tilde{\sigma}_{q,t}}.$$

此时 $n_{q,t} = 8$ ，样本标准差分母仍为 7。同一步骤的全部有效输出 token 共用 $A_{i,t}^G$ ，不除以本步 token 数。

5.2 信号的含义与适用边界

成功轨迹也可出现负的步骤相对优势；即使终局奖励全相同，只要过程评分不同，仍可能得到非零优势。绝对 PRM 分数为正也不保证组内优势为正，优势取决于相对合成奖励。 $n_{q,t} < 8$ 时是否按实际存在步骤的子组标准化，以及过程评分缺失或失败时的处理，均未确定。本记录不补齐缺失步骤、不默认为零、不删除样本，也不固定 η 。步骤评分可以异步产生，但更新需等待本批所需终局奖励、过程评分与优势就绪。

6 四种设定共享：终局校准同伴信号

6.1 用实际最终答案计算教师偏好

锁定教师后，在接收者自己的轨迹上做 teacher-forcing 评分。 F_i 是实际最终答案的 token 位置集合，位置由 (t, k) 标识。其提取边界保持输入接口，不把整条工具反馈序列自动当作最终答案。

$$J_i = \frac{1}{|F_i|} \sum_{(t,k) \in F_i} [\log \pi_T(y_{i,t,k} \mid h_{i,t,k}) - \log \pi_{\text{old}}(y_{i,t,k} \mid h_{i,t,k})], \quad |F_i| > 0. \quad (15)$$

J_i 是同一段实际答案上“教师减旧模型”的平均 logprob 差。它使用完整词表概率，计算前不进行差值裁剪。 $J_i > 0$ 表示教师更支持这段答案， $J_i < 0$ 表示支持较低；它不是教师自身解题成功率。

6.2 保留、反转或关闭同伴 OPD

$$\lambda_i = \begin{cases} 0, & |F_i| = 0, \\ +1, & |F_i| > 0 \wedge (O_i J_i > 0 \vee J_i = 0), \\ -1, & |F_i| > 0 \wedge O_i J_i < 0. \end{cases} \quad (16)$$

O_i	J_i	λ_i	信号方向
+1	> 0	+1	保留：教师支持正确答案
+1	< 0	-1	反转：教师压低正确答案
-1	< 0	+1	保留：教师压低错误答案
-1	> 0	-1	反转：教师支持错误答案

非空答案的 $J_i = 0$ 时取 $\lambda_i = +1$ ，平均差值为零不代表局部差值为零。空最终答案取 $\lambda_i = 0$ ，不计算 J_i ，该轨迹同伴 OPD 项显式为零，GRPO 分组与优势保留。空最终答案不等于没有动作 token。无可用教师时，整批没有同伴 OPD，仍保留 GRPO 与参考 KL。有教师且最终答案为空时，零 OPD 项仍计入 128 条轨迹的批次平均，不只对非零项重新归一化。开启 PRM 后， O_i 仍是终局正确性奖励， λ_i 仍是轨迹级方向；不把 $R_{i,t}$ 自动代入本式，也不自动改成逐步 $\lambda_{i,t}$ 。PRM 改变 GRPO 优势，而非这项同伴方向规则。

7 四种设定共享：旧模型 top-4 同伴 OPD

7.1 固定候选与概率权重

在每个有效输出前缀 $h_{i,t,k}$ 上，取本轮本地旧模型的 top-4。评分与优化期间候选身份保持固定，教师与当前模型对相同候选评分：

$$S_{i,t,k} = \text{Top4}(\pi_{\text{old}}(\cdot \mid h_{i,t,k})), \quad |S_{i,t,k}| = 4. \quad (17)$$

$$\ell_{i,t,k,v}^X = \log \pi_X(v \mid h_{i,t,k}), \quad X \in \{\text{old}, T, \theta\}. \quad (18)$$

三种模型的概率均来自完整词表 softmax。只有用于候选加权的 w 在 top-4 内归一化：

$$w_{i,t,k,v} = \frac{\exp(\ell_{i,t,k,v}^{\text{old}})}{\sum_{u \in S_{i,t,k}} \exp(\ell_{i,t,k,u}^{\text{old}})}, \quad \sum_{v \in S_{i,t,k}} w_{i,t,k,v} = 1. \quad (19)$$

7.2 差值裁剪、轨迹符号与梯度流

$$d_{i,t,k,v} = \ell_{i,t,k,v}^T - \ell_{i,t,k,v}^{\text{old}}, \quad \Delta_{i,t,k,v} = \text{clip}(d_{i,t,k,v}, -C, C). \quad (20)$$

$$\boxed{a_{i,t,k,v}^{\text{peer}} = \text{sg}[\lambda_i w_{i,t,k,v} \Delta_{i,t,k,v}]}, \quad \lambda_i \in \{-1, +1\}. \quad (21)$$

C 是尚未赋值的对称差值裁剪阈值，sg 表示 stop-gradient。旧模型、教师、候选身份、权重、差值和 λ_i 固定；只有当前本地策略概率接收训练梯度。 $\lambda_i = 0$ 直接采用零 OPD 损失分支。每个有效输出位置产生 4 个候选优势，而非一个简单加到实际采样 token 上的 PRM 分数。对候选损失求和时不再除以 4，因为 w 已归一化。实际采样 token 可能不在 top-4 内，因此计算 J_i 所需的实际答案 logprob 也必须单独保留。伪教师、旧模型和当前模型在同一个真实前缀上评分；工具反馈必须按实际输入保留。教师不重新执行另一条环境路径。 $\lambda_i = -1$ 在进入 min/clip 前反转候选优势，不能先计算普通 OPD 裁剪损失再整体乘负号。

8 分别裁剪、两层平均与参数更新

GRPO 在实际采样 token 上计算新旧本地策略比率，OPD 在 top-4 候选上计算比率；教师不是分母：

$$r_{i,t,k} = \frac{\pi_{\theta}(y_{i,t,k} | h_{i,t,k})}{\pi_{\text{old}}(y_{i,t,k} | h_{i,t,k})}, \quad (22)$$

$$\rho_{i,t,k,v} = \frac{\pi_{\theta}(v | h_{i,t,k})}{\pi_{\text{old}}(v | h_{i,t,k})}.$$

$$c_X(r) = \text{clip}(r, 1 - \epsilon_X^{\text{low}}, 1 + \epsilon_X^{\text{high}}), \quad X \in \{G, D\}. \quad (23)$$

两分支独立使用 PPO clipped surrogate, A^G 由 PRM 开关决定：

$$L_{i,t,k}^G = -\min\{r_{i,t,k}A_{i,t,k}^G, c_G(r_{i,t,k})A_{i,t,k}^G\}. \quad (24)$$

$$U_{i,t,k}^{\text{peer}} = -\sum_{v \in S_{i,t,k}} \min\left\{\rho_{i,t,k,v}a_{i,t,k,v}^{\text{peer}}, c_D(\rho_{i,t,k,v})a_{i,t,k,v}^{\text{peer}}\right\}, \quad (25)$$

$$L_{i,t,k}^{\text{peer}} = \begin{cases} 0, & \lambda_i = 0, \\ U_{i,t,k}^{\text{peer}}, & \lambda_i \in \{-1, +1\}. \end{cases}$$

8.1 先在轨迹内平均，再对完整轨迹平均

对分支 X ，按其掩码聚合所有步骤的有效输出 token，随后以完整轨迹为单位平均：

$$\bar{L}_i^X = \frac{\sum_{t=1}^{T_i} \sum_{k \in M_{i,t}^X} L_{i,t,k}^X}{\sum_{t=1}^{T_i} |M_{i,t}^X|}, \quad \sum_t |M_{i,t}^X| > 0, \quad (26)$$

$$\mathcal{L}_{\text{total}} = \frac{1}{B} \sum_{i=1}^B \left(\alpha \bar{L}_i^G + \beta \bar{L}_i^{\text{peer}} \right) + 0.01 \mathcal{L}_{\text{KL}}, \quad B = 128.$$

每条轨迹的批次权重为 1/128。不先做步骤等权平均，不平均所有展开的 Terminal 步骤样本，也不做全批次 token 等权平均。 α, β 保持未定符号；两种优势不先相加后只裁剪一次。参考 KL 使用相同两层汇总， κ_{θ} 只是所选 token 级参考惩罚的记号，不是额外模型：

$$\mathcal{L}_{\text{KL}} = \frac{1}{B} \sum_{i=1}^B \frac{\sum_t \sum_{k \in M_{i,t}^K} \kappa_{\theta}(h_{i,t,k}, y_{i,t,k}; \pi_{\text{ref}})}{\sum_t |M_{i,t}^K|}. \quad (27)$$

参考策略身份、确切 KL 数值实现与掩码仍为输入接口，系数已定为 0.01。该项梯度流向本地当前策略，不乘 λ_i 。各分支若存在空动作掩码，分母没有定义，其处理未指定；不能由空最终答案的规则推出。最后对联合损失反向传播并优化本地参数，没有额外再执行一次 GRPO。

9 设定一与二：Terminal 的算法与流程

Terminal 把一条完整轨迹拆成逐步样本，每份保存当时真实输入与当前输出，同时保留完整轨迹身份：

$$\tau_i \mapsto \{(s_{i,t}, a_{i,t}, i, t) : t = 1, \dots, T_i\}. \quad (28)$$

样本	当前输入	当前训练目标
第 1 份	任务与初始观察 $s_{i,1}$	第一步思考 + 操作 $a_{i,1}$
第 2 份	保留第 1 步及反馈的 $s_{i,2}$	第二步思考 + 操作 $a_{i,2}$
第 3 份	保留此前交互的 $s_{i,3}$	第三步思考 + 回答 $a_{i,3}$

历史中的旧动作仅作为这一份样本的输入，不再次成为该份的输出训练目标。教师对每份样本使用完全相同的当前输入。

9.1 设定一：Terminal, PRM 关闭

1. 固定旧策略，按 16 道题各收集 8 条完整轨迹；存下各步输入、输出、旧 logprob 与轨迹身份。
2. 外部裁判提供 O_i ；按同题完整轨迹计算 A_i^G ，奖励只计一次。
3. 所有步骤输出 token 使用同一个 A_i^G ；优势完成时锁定缓存教师，按共同 OPD 规则计算信号。
4. 各步计算双分支损失，按完整轨迹还原 token 均值，再平均 128 条轨迹，加入 KL、更新、广播。

9.2 设定二：Terminal, PRM 开启

1. 保留相同 rollout 与拆样本方式，另取得每步 $P_{i,t}$ 。
2. 取得终局 O_i 后合成 $R_{i,t} = O_i + \eta P_{i,t}$ ，按同题、同一步骤分组得到 $A_{i,t}^G$ 。
3. 第 t 份样本的全部有效输出 token 使用 $A_{i,t}^G$ ；本批所需优势完成时锁定教师。
4. OPD 的 J_i, λ_i 与 top-4 规则保持原样；仍按完整轨迹平均并完成本地更新、广播。

即使一条轨迹拆成 7 份样本，批次中它仍是一条轨迹，其权重仍为 1/128。PRM 改变 GRPO 信号来源，不改变终局 OPD 门控或引入每步更新。

10 设定三与四：Tool-call 的算法与流程

Tool-call 累计模型输出和工具反馈，存为一份完整长样本。每个模型输出位置保留真实上下文；因果注意力使其只读取此前信息，不读取未来工具结果。

长序列片段	mask	PRM 关闭的优势	PRM 开启的优势
任务与提示	0	无直接动作 loss	无直接动作 loss
第 1 步思考 + 调用	1	A_i^G	$A_{i,1}^G$
第 1 次工具返回	0	无直接动作 loss	无直接动作 loss
第 2 步思考 + 调用	1	A_i^G	$A_{i,2}^G$
第 2 次工具返回	0	无直接动作 loss	无直接动作 loss
最终思考 + 回答	1	A_i^G	$A_{i,3}^G$

mask 为 0 不代表不可见：工具返回仍影响后续生成。用 p 表示长序列位置， ϕ_i 把步骤内位置映射到长序列：

$$p = \phi_i(t, k), \quad h_{i,p} = h_{i,t,k}, \quad A_{i,p}^G = A_{i,t,k}^G. \quad (29)$$

10.1 设定三：Tool-call, PRM 关闭

1. 旧策略逐轮生成动作，执行工具并追加实际观察，记录输出 mask 和旧 logprob，收集 128 条完整长轨迹。
2. 裁判给终局 O_i ，问题 8 条计算一次 A_i^G ；该轨迹所有有效输出位置使用此值。
3. 优势完成时按缓存协议锁定教师，读取带工具反馈的同一前缀，计算 J_i, λ_i 和 top-4 OPD。
4. 只在输出位置计算两分支动作损失；按轨迹内有效 token 平均，再做批次平均，更新并广播。

10.2 设定四：Tool-call, PRM 开启

1. 保留长序列与 mask，另记录各步输出范围并取得 $P_{i,t}$ 。
2. 终局评分后合成 $R_{i,t}$ ，按问题、相同步骤计算 $A_{i,t}^G$ ，原样赋给该步范围内的输出 token。
3. 优势完成时锁定教师；OPD 仍依照原有终局方向和每个输出前缀的 top-4 计算。
4. 分别裁剪、按轨迹平均、按批次平均，加入参考 KL 后更新并广播。

长序列是一种存储方式，不要求其中所有 token 共用优势。若上下文、有效位置和汇总规则相同，按步拆样本与长序列存储可以表达相同训练目标。

11 统一事件循环与方法边界

11.1 每个 Agent 的完整算法

以下循环独立运行于每个 Agent；所选 Terminal/Tool-call 与 PRM 开关决定数据组织和 GRPO 优势。

1. **开始本轮**。清空旧缓存；固定本轮旧策略，从本地旧参数开始当前策略，接收 16 道题并各采样 8 条完整轨迹。
2. **持续交互与接收**。模型输出思考和动作，执行后获得观察并形成下一步输入；同伴广播写入本轮缓存。PRM 开启时额外取得步骤分数。
3. **判题与构造优势**。获得全部终局正确性奖励。PRM 关闭时按完整轨迹分组，开启时先合成步骤奖励再按步骤分组；有效步骤 token 原样获得其优势。
4. **锁定教师**。在优势完成事件上选择最新到达快照，纳入同时到达条目，并列均匀抽样。为空则采用 GRPO + KL 分支，否则锁定教师。
5. **本地轨迹评分**。锁定教师评分本批真实前缀，取得实际答案与旧模型 top-4 候选的 logprob；计算 $J_i, \lambda_i, w, \Delta, a^{\text{peer}}$ 。教师始终冻结。
6. **本地优化**。当前策略重算概率比，分别形成 GRPO 与 OPD clipped loss；先按轨迹平均 token，再平均 128 条轨迹并组合 KL。只更新本地指定参数。
7. **广播与继续**。优化结束立即广播不可变新快照；允许接题时进入下一轮并再次清空缓存。迟到快照不改变已锁定教师。
8. **停止与收尾**。接到停止信号后完成已开始的 rollout、评分和更新；收尾更新同样广播。停止触发标准仍是外部输入。

11.2 已确认约定与 PRM 扩展的边界

已确认基线不开 PRM。两种 PRM 开启设定记录结构性扩展，未替代原基线。 η, α, β, C 和各分支裁剪范围保留符号；缺少步骤、无有效奖励和空动作掩码的处理未被补成默认规则。本文不展开实验、解码、算力预算等配置。本记录沿用用户的样本标准差、零标准差替换和保留奖励常数组约定。OpenClaw-RL 当前步骤路径采用总体标准差加小量，并筛除部分常数组；这些行为没有移植。其 Terminal 合成式含过程系数，而 Tool-call 的逐步字段直接为 $O_i + P_{i,t}$ ，可配过程系数用于另一处轨迹总分。本文用符号 η 表示统一扩展，不宣称两个原始分支都已实现同样权重。同伴方向校准不保证局部动作正确，也不保证成功率单调提升。本文记录算法与流程，没有训练运行或实验结果。